

1. Dérivations manuscrites

1.1. Dérivez les règles VSP pour l'opération matmul(W, x), c'est-à-dire $\frac{\partial L}{\partial W}$ et $\frac{\partial L}{\partial x}$.

$z = Wx$ avec $W \in \mathbb{R}^{m \times n}$ et $x \in \mathbb{R}^n$, $z \in \mathbb{R}^m$


$$z_i = \sum_j W_{ij} x_j$$

entrée du VSP $\Rightarrow \bar{z} = \frac{\partial L}{\partial z} \in \mathbb{R}^m$

$$\frac{\partial L}{\partial W_{ij}} = \frac{\partial L}{\partial z_i} \cdot \frac{\partial z_i}{\partial W_{ij}} = \bar{z}_i \cdot x_j \quad \xrightarrow{\text{forme matricielle}} \quad \frac{\partial L}{\partial W} = \bar{z} \cdot x^T$$

$$\frac{\partial L}{\partial x_j} = \sum_i \frac{\partial L}{\partial z_i} \cdot \frac{\partial z_i}{\partial x_j} = \sum_i \bar{z}_i \cdot W_{ij} \quad \xrightarrow{\text{forme matricielle}} \quad \frac{\partial L}{\partial x} = W^T \bar{z}$$

1.2. Dessinez le graphe de calcul complet du MLP à 2 couches, de l'entrée jusqu'à la perte, et annotez les VSP



2.2. Calcul d'attention à la main

SIMILES CO avec $d_{\text{model}}=4$ et $d_k=2$

$$E = \begin{pmatrix} 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{pmatrix}$$

$$Q = EW_Q = \begin{pmatrix} 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 2 & 1 \\ 0 & 1 \end{pmatrix}$$

$$K = EW_K = \begin{pmatrix} 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 0 & 1 \\ 1 & 0 \\ 0 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 0 & 2 \\ 0 & 2 \\ 2 & 0 \end{pmatrix}$$

$$V = EW_V = \begin{pmatrix} 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 0 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 2 & 1 \\ 0 & 1 \end{pmatrix}$$

$$(2) S = \frac{QK^T}{\sqrt{d_k}}$$

$$QK^T = \begin{pmatrix} 2 & 1 \\ 2 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 0 & 0 & 2 \\ 2 & 2 & 0 \end{pmatrix} = \begin{pmatrix} 2 & 2 & 4 \\ 2 & 2 & 4 \\ 2 & 2 & 0 \end{pmatrix}$$

$$S = \frac{QK^T}{\sqrt{2}} = \begin{pmatrix} \sqrt{2} & \sqrt{2} & 2\sqrt{2} \\ \sqrt{2} & \sqrt{2} & 2\sqrt{2} \\ \sqrt{2} & \sqrt{2} & 0 \end{pmatrix}$$

(3) Softmax

$$L_1 = L_2 \quad e^{\sqrt{2}} = 4,113 \quad e^{2\sqrt{2}} = 16,919$$

$$e^{\sqrt{2}} + e^{\sqrt{2}} + e^{2\sqrt{2}} = 4,113 + 4,113 + 16,919 = 25,145$$

$$A_1 = A_2 = [0,1636; 0,1636; 0,6727]$$

L_3

$$e^0 = 1$$

$$e^0 + e^{\sqrt{2}} + e^{\sqrt{2}} = 1 + 4,113 + 4,113 = 9,226$$

$$A_3 = [0,4459; 0,4459; 0,1084]$$

$$A = \text{softmax}(S) \approx \begin{pmatrix} 0,164 & 0,164 & 0,673 \\ 0,164 & 0,164 & 0,673 \\ 0,446 & 0,446 & 0,108 \end{pmatrix}$$

(4) Sortie $O = AV$

$$O = \begin{pmatrix} 0,164 & 0,164 & 0,673 \\ 0,164 & 0,164 & 0,673 \\ 0,446 & 0,446 & 0,108 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 2 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 0,655 & 1 \\ 0,655 & 1 \\ 1,784 & 1 \end{pmatrix}$$